

TÌM HIỂU VỀ BÀI TOÁN TEXT-TO-SPEECH

1. Tìm hiểu tổng quan về bài toán, tình hình nghiên cứu, các phương pháp triển khai.

Text-to-Speech (TTS) là bài toán chuyển đổi văn bản thành giọng nói bằng máy tính. Mục tiêu của hệ thống chuyển văn bản thành giọng nói là ánh xạ một chuỗi ký tự đầu vào sang dạng sóng âm thanh đầu ra sao cho giọng nói tổng hợp có độ tự nhiên cao, rõ ràng và dễ nghe.

Các hệ thống TTS hiện đại thường được xây dựng dựa trên kiến trúc encoder-decoder, trong đó encoder chịu trách nhiệm mã hóa thông tin văn bản và decoder sinh ra đặc trưng giọng nói hoặc trực tiếp tạo sóng âm. Những kiến trúc này phổ biến sử dụng LSTM hoặc Transformer. Trong nhiều hệ thống TTS cơ bản, việc sử dụng nhiều giọng nói không phải là mục tiêu chính, do đó mô hình thường phụ thuộc vào người nói, tức là được huấn luyện trên dữ liệu của một người nói duy nhất nhằm đảm bảo sự nhất quán của giọng và giảm yêu cầu về lượng dữ liệu huấn luyện.

Trong những năm gần đây, bài toán Text-to-Speech đã có sự phát triển mạnh mẽ và trở thành một lĩnh vực nghiên cứu quan trọng trong xử lý tiếng nói. Các phương pháp TTS truyền thống như ghép nối âm thanh (concatenative TTS) phụ thuộc vào các đoạn ghi âm cố định, dẫn đến hạn chế về tính linh hoạt và độ tự nhiên. Tiếp theo đó, các hệ thống thống kê dựa trên mô hình HMM được đề xuất, tuy cải thiện khả năng tổng hợp nhưng chất lượng giọng nói vẫn còn hạn chế và khó điều khiển.

Bước ngoặt quan trọng xuất hiện khi các mô hình học sâu được áp dụng, đặc biệt là WaveNet (2016), một vocoder thần kinh có khả năng sinh sóng âm trực tiếp với độ trung thực rất cao. Sau đó, các mô hình như Tacotron và Tacotron 2 đã giới thiệu kiến trúc end-to-end, trong đó văn bản được chuyển thành mel-spectrogram trước khi được vocoder tổng hợp thành âm thanh. Tuy nhiên, các mô hình autoregressive này vẫn tồn tại hạn chế về tốc độ suy luận và độ ổn định.

Để khắc phục các nhược điểm trên, các kiến trúc phi-autoregressive như FastSpeech và FastSpeech 2 đã được đề xuất, giúp tăng tốc độ tổng hợp và giảm lỗi đọc. Giai đoạn hiện nay chứng kiến sự phát triển mạnh mẽ của các mô hình sinh dữ liệu thế hệ mới như GAN, Normalizing Flow và Diffusion. Trong đó, VITS là một cột mốc quan trọng khi kết hợp mô hình sinh đặc trưng và vocoder trong một hệ thống end-to-end duy nhất, giúp tạo giọng nói tự nhiên và dễ huấn luyện hơn. Bên cạnh đó, các mô hình diffusion

như Grad-TTS hay DiffWave cũng góp phần cải thiện độ mượt và chi tiết của âm thanh tổng hợp. Ngoài ra, các hướng nghiên cứu mới còn tập trung vào điều khiển ngữ điệu, cảm xúc, hỗ trợ đa ngôn ngữ và voice cloning với lượng dữ liệu rất nhỏ, tiêu biểu như VALL-E, Meta Voicebox hay OpenAI TTS.

Trong thực tế, việc triển khai TTS thường đi theo ba hướng chính, bao gồm pipeline truyền thống, mô hình end-to-end và sử dụng các mô hình hoặc công cụ có sẵn.

2. Với từng hướng triển khai kết luận được ưu/nhược điểm, phù hợp vs các trường hợp sử dụng cụ thể nào.

Khi triển khai hệ thống Text-to-Speech, có ba hướng chính thường được sử dụng, mỗi hướng có những ưu điểm, nhược điểm và phạm vi ứng dụng riêng.

Hướng 1: Pipeline truyền thống (text processing $\rightarrow$ acoustic model $\rightarrow$ vocoder)

- Quá trình tổng hợp giọng nói được chia thành ba bước độc lập: xử lý văn bản, sinh đặc trưng giọng nói và vocoder tạo sóng âm.
- Ưu điểm: Dễ tùy chỉnh và kiểm soát từng thành phần riêng lẻ, linh hoạt cho nghiên cứu và thử nghiệm.
- Nhược điểm: Quy trình phức tạp, khó tối ưu đồng bộ toàn hệ thống, yêu cầu kiến thức chuyên sâu.
- Phù hợp: Nghiên cứu học thuật, phát triển các hệ thống TTS đặc thù hoặc thử nghiệm nhiều mô-đun khác nhau.

Hướng 2: Mô hình end-to-end (ví dụ: VITS, Glow-TTS, FastSpeech + vocoder tích hợp)

- Toàn bộ pipeline từ văn bản đến âm thanh được gộp trong một mô hình duy nhất.
- Ưu điểm: Triển khai đơn giản, dễ huấn luyện đồng bộ, chất lượng giọng nói tự nhiên và ổn định, tốc độ suy luận nhanh.
- Nhược điểm: Khó can thiệp sâu vào từng thành phần, khả năng điều khiển ngữ điệu và cảm xúc phụ thuộc nhiều vào dữ liệu, yêu cầu tài nguyên tính toán cao khi huấn luyện.

- Phù hợp: Xây dựng sản phẩm thực tế như chatbot, trợ lý ảo hoặc huấn luyện giọng mới từ dữ liệu riêng.

Hướng 3: Sử dụng mô hình hoặc công cụ sẵn có (Coqui TTS, NVIDIA NeMo, Google/Meta/Azure TTS API)

- Sử dụng các thư viện mã nguồn mở hoặc dịch vụ TTS thương mại đã được phát triển sẵn.
- Ưu điểm: Triển khai nhanh, chất lượng ổn định, hỗ trợ nhiều giọng nói và ngôn ngữ, tiết kiệm chi phí phát triển.
- Nhược điểm: Ít quyền kiểm soát giọng và ngữ điệu, phụ thuộc vào bên thứ ba, hạn chế tùy chỉnh sâu.
- Phù hợp: Ứng dụng thương mại cần triển khai nhanh, không có nhiều dữ liệu hoặc tài nguyên phần cứng.

3. Cách các nghiên cứu tạo pipeline để tối thiểu hoá nhược điểm cho từng hướng tiếp cận hiện tại, cũng như tối đa hoá ưu điểm của chúng.

Đối với các hệ thống TTS triển khai theo pipeline truyền thống, nhược điểm lớn nhất là quy trình phức tạp và khó đồng bộ. Để khắc phục, các nghiên cứu hiện nay tập trung vào việc chuẩn hóa và mô-đun hóa pipeline, trong đó mỗi bước có giao diện đầu vào và đầu ra rõ ràng. Cách tiếp cận này giúp dễ dàng kiểm tra, thay thế hoặc cải tiến từng thành phần mà không ảnh hưởng đến toàn bộ hệ thống. Đồng thời, việc áp dụng các mô hình neural hiện đại cho từng khâu, kết hợp với kỹ thuật alignment và attention, giúp nâng cao chất lượng giọng nói và giảm lỗi nhịp điệu.

Đối với hướng mô hình end-to-end, nhược điểm chính là khó kiểm soát từng thành phần và phụ thuộc nhiều vào dữ liệu huấn luyện. Các nghiên cứu khắc phục bằng cách thiết kế mô hình đa nhiệm hoặc sử dụng latent representation, tiêu biểu như VITS với variational inference và flow-based model, cho phép tách biệt nội dung, giọng nói và ngữ điệu. Ngoài ra, việc huấn luyện trên dữ liệu đa dạng kết hợp với data augmentation giúp mô hình học được sự biến thiên tự nhiên của giọng nói và cải thiện khả năng tổng quát hóa.

Đối với hướng sử dụng mô hình hoặc công cụ sẵn có, để giảm sự phụ thuộc và tăng khả năng kiểm soát, các nghiên cứu và ứng dụng thực tế thường áp dụng fine-tuning hoặc transfer learning trên các mô hình pre-trained. Bên cạnh đó, việc tiền xử lý văn bản trước khi đưa vào hệ thống, như chuẩn hóa, tách câu hoặc tokenization, cũng góp phần cải thiện chất lượng giọng đọc, giảm lỗi và đảm bảo âm thanh tổng hợp ổn định hơn.